

Transformers

Comprendre la révolution du NLP

Diallo Sidy Mohamed Salim - DSE

Kebe Mohamed - DSE

Année 2026

Plan de l'exposé

1. **Introduction au NLP**
Définition et applications majeures
2. **Les approches classiques**
N-grammes, embeddings statiques, RNN/LSTM
3. **La révolution Transformers (2017)**
"Attention Is All You Need"
4. **Le mécanisme Self-Attention**
Intuition et formalisme Q, K, V
5. **Multi-Head Attention**
Multiplier les points de vue
6. **Architecture globale**
Encoder-Decoder, composants clés
7. **Inputs & Outputs d'un Transformer**
Schéma détaillé du flux de données
8. **Pourquoi ils dominent**
Comparaison et avantages
9. **Limites et défis**
Complexité, hallucinations, coûts
10. **Conclusion**
Héritiers et perspectives

Une révolution silencieuse

"En 2017, on a prouvé qu'on pouvait comprendre une phrase sans la lire dans l'ordre, mais en regardant tous les mots en même temps."




Une transformation profonde qui a donné naissance à **ChatGPT**, **BERT** et toute la génération actuelle d'IA.

Le NLP : Traiter le langage humain

Définition : Branche de l'IA visant à doter les machines de la capacité de *comprendre*, interpréter et produire du langage naturel.

Applications majeures :

- Traduction (DeepL, Google Translate)
- Assistants vocaux (Siri, Alexa)
- Chatbots (ChatGPT, Claude, Gemini)
- Résumé et extraction d'informations
- Analyse de sentiments
- Reconnaissance d'entités nommées (NER)



Défi central : l'ambiguïté du langage (polysémie, contexte, ironie).

Ex : "La petite brise la glace" → qui brise quoi ?

Le mur des architectures classiques

Avant 2017, trois grandes familles dominaient, chacune avec ses limites :

- **N-grammes** : Probabilité d'apparition de séquences de 2-3 mots. Contexte trop court. Ex : "L'avion de..." → "ligne" ? "papier" ? "chasse" ?
- **Embeddings statiques (Word2Vec, GloVe)** : Un seul vecteur figé par mot. "Avocat" identique au tribunal et dans une salade.
- **RNN / LSTM / GRU** : Lecture séquentielle obligatoire, mot après mot. Mémoire interne limitée.




Le problème fatal

Impossibilité de paralléliser, perte d'information sur les longues phrases (*vanishing gradient*), incapacité à capter les dépendances à longue distance.

2017 : "Attention Is All You Need"

Passage du traitement **séquentiel** au traitement **parallèle**. Vaswani et al. (Google Brain), NeurIPS 2017.

- **Suppression de la récurrence** : Toute la phrase est donnée d'un coup au modèle.
- **Attention Globale** : Chaque mot peut se connecter directement à n'importe quel autre.
- **Scalabilité massive** : Exploitation pleine des GPU/TPU sur des milliards de mots.
- **Modularité** : Blocs encodeur/décodeur empilables et adaptables.
- **Reproductibilité** : Architecture publique qui a démocratisé la recherche.




Connexions tous-à-tous.

Intuition du Self-Attention

Comment définir un mot par ses voisins ? En regardant toute la phrase et en pondérant chaque mot.

Exemple : "L'animal n'a pas traversé la rue car **il** était trop fatigué."



- Calcul d'un **score de pertinence** entre chaque paire de mots.
- Le pronom "il" se focalise sur "animal" → résolution d'*anaphore*.
- La représentation de "il" devient **contextuelle** et porte l'information de "animal".
- Contrairement aux embeddings statiques, le vecteur change selon la phrase.

Query, Key, Value : L'analogie du moteur de recherche


Pour chaque mot, on projette son embedding dans 3 espaces via W_Q , W_K , W_V :

1. **Query (Q)** : "Ce que je cherche" → Ma question.
2. **Key (K)** : "Ce que je propose" → Mon étiquette.
3. **Value (V)** : "Ce que je contiens" → Mon information.

Le calcul mathématique

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Le produit scalaire QK^T mesure la similarité, $\sqrt{d_k}$ stabilise les gradients, le softmax convertit en probabilités.




Multi-Head Attention : Multiplier les points de vue

Pourquoi plusieurs têtes ?

Un mot a *simultanément* plusieurs types de relations :


- **Tête 1** : Syntaxe (Sujet-Verbe, accords).
- **Tête 2** : Sémantique (anaphore, coréférence).
- **Tête 3** : Structure et ponctuation.
- **Tête 4** : Dépendances longue distance.

Le modèle "regarde" la phrase à travers **8 ou 16 prismes** simultanément, puis concatène et projette via W_O pour une représentation unifiée.



Chaque tête a ses propres W_Q , W_K , W_V .

L'Architecture globale (Encoder-Decoder)




Bloc Encodeur ($\times N$)

*$N = 6$ dans le Transformer original, jusqu'à
 $N = 96$ pour GPT-3.*

Composants essentiels :

- **Positional Encoding** : Signal sinusoïdal ajouté pour indiquer la position de chaque mot.
- **Residual Connections** : Réinjection de l'info brute ($x + f(x)$) pour faciliter la rétropropagation.
- **Feed-Forward Network** : Réseau dense à 2 couches appliqué position par position (ReLU/GELU).
- **Layer Normalization** : Stabilise l'apprentissage et accélère la convergence.

Inputs & Outputs d'un Transformer



Pourquoi les Transformers dominant-ils ?

Critère	N-gram	RNN / LSTM	Transformers
Parallélisation	✓	×	✓✓
Contexte long	×	Moyen	✓✓
Sémantique dynamique	×	✓	✓✓
Entraînement massif	✓	Lent	Rapide
Transfer learning	×	Limité	✓✓
Multimodalité	×	×	✓✓

- **SOTA** : Records sur tous les benchmarks (GLUE, SuperGLUE, SQuAD, MMLU).
- **Versatilité** : Au-delà du texte → images (ViT), audio (Whisper), biologie (AlphaFold).
- **Scaling Laws** : Plus de paramètres + données = performance prédictible et capacités émergentes.
- **Transfer learning** : Pré-entraînement massif + fine-tuning → démocratisation de l'IA.

Les limites : Le revers de la médaille

Limitations Techniques :

- **Complexité $O(N^2)$** : Coût quadratique en longueur. Doubler la phrase quadruple l'effort GPU.
- **Fenêtre fixe** : "Amnésie" au-delà d'une limite (8k, 32k tokens).
- **Lost in the Middle** : Difficulté à porter attention au milieu des longs documents.

Limitations Cognitives & Coûts :

- **Hallucinations** : "Perroquets stochastiques" sans modèle mental ni ancrage réel.
- **Longue Traîne (Zipf)** : Mauvaise représentation des concepts rares.
- **Coûts & Centralisation** : Entraînement à des millions \$, impact écologique lourd.

Défi futur : architectures linéaires (Mamba, SSM) et raisonnement plus fiable.

Conclusion : Une révolution en marche

Les héritiers majeurs :

- **BERT** (Google, 2018) : Encodeur bidirectionnel, roi de la compréhension.
- **GPT** (OpenAI, 2018-2024) : Décodeur autorégressif, de 117M à 1.7T de paramètres.
- **T5** (Google, 2019) : Approche text-to-text unifiée.
- **LLaMA, Claude, Gemini** : Multimodalité, raisonnement avancé, agents autonomes.

De la statistique...

...à l'Attention.

Une seule architecture, des milliers d'applications.

À retenir : Les Transformers ont supprimé la contrainte de l'ordre linéaire pour embrasser la **complexité globale** du langage, ouvrant la voie aux modèles de fondation et à l'IA générative moderne.

-  A. Vaswani, N. Shazeer, N. Parmar, et al.
Attention Is All You Need.
NeurIPS, 2017.
-  J. Devlin, M. Chang, K. Lee, and K. Toutanova.
BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding.
arXiv preprint, 2018.
-  D. Bahdanau, K. Cho, and Y. Bengio.
Neural Machine Translation by Jointly Learning to Align and Translate.
ICLR, 2015.



T. Mikolov, K. Chen, G. Corrado, and J. Dean.

Efficient Estimation of Word Representations in Vector Space.

ICLR, 2013.